RELATÓRIO TÉCNICO

Projeto de Análise de Dados do German Credit



linkedin.com

Análise Exploratória com Python e Power BI

Blanca Rosa Maquera Sosa

Novembro de 2026

Sumário

1. Introdução e Objetivos 4

2.Base de dados e variáveis 4

2.1. Descrição das variáveis 5

2.2. Visualização inicial dos dados 6

3. Análise das variáveis quantitativas com Python 7

3.1 Medidas descritivas 7

3.1.1 Duração do crédito 7

3.1.2 Idade 8

3.1.3 Valor do crédito 8

3.1.4 Número de créditos 8

3.1.5 Número de dependentes 8

3.2 Distribuição das variáveis 9

3.2.1 Distribuição da duração do crédito 10

3.2.2 Distribuição do valor do crédito 10

3.2.3 Distribuição da idade 10

3.2.4 Distribuição do número de créditos 10

3.2.5 Distribuição do número de dependentes 10

3.3 Assimetria e curtose 10

3.4 Análise da correlação entre as variáveis quantitativas 12

3.4.1 Matriz de correlação de Pearson 12

3.4.2 Matriz de correlação de Spearman 13

3.4.3 Comparação entre as matrizes de Pearson e Spearman 14

4. Análise exploratória das variáveis qualitativas 15

4.1 Conta corrente 16

4.2 Histórico de crédito 17

4.3 Conta poupança 18

4.4 Finalidade do crédito 19

4.5 Patrimônio 20

4.6 Síntese da análise das variáveis qualitativas 21

5. Teste do qui-quadrado e V de Cramér 21

5.1 Resultados dos testes 21

5.2 Interpretação dos resultados 23
6. Análise dos resíduos padronizados de Pearson 23
6.1 Principais resultados 24
6.2 Interpretação dos resultados 25
7. Visualização e Análise dos Dados com Power BI 27
7.1 Visão Geral do German Credit 27
7.2 Perfil dos Clientes 27
7.3 Características do Crédito 28
7.4 Análise Exploratória de Variáveis Quantitativas 28
7.5 Análise Exploratória de Variáveis Qualitativas 29
7.6 Análise de Resíduos 29
8. Principais conclusões da análise exploratória 30
9. Limitações da análise 31
10. Próxima etapa do projeto 31
11. Conclusão final 32
APÊNDICE A – Código Python utilizado na Análise Exploratória de Dados. 33
Referências bibliográficas 45

1. Introdução e Objetivos

A análise de crédito é uma importante aplicação da Estatística e da Ciência de Dados, pois permite identificar características associadas ao risco de inadimplência e apoiar processos de avaliação e tomada de decisão.

Neste projeto, é analisado o conjunto de dados *German Credit*, composto por informações referentes a clientes que solicitaram crédito. O conjunto apresenta variáveis quantitativas e qualitativas relacionadas às características pessoais, financeiras e às condições de concessão de crédito dos clientes, além da variável classe_credito, que representa a classificação do crédito.

O objetivo da primeira parte deste projeto é realizar uma análise descritiva e exploratória dos dados, com ênfase nas variáveis qualitativas, buscando compreender a distribuição de suas categorias, identificar padrões e investigar possíveis associações com a classificação de crédito.

As variáveis quantitativas são analisadas por meio de medidas estatísticas descritivas, representações gráficas e análise de correlação, com o propósito de compreender suas distribuições, identificar padrões e examinar possíveis relações entre elas.

Em relação às variáveis qualitativas, são utilizadas tabelas de frequências, tabelas cruzadas e representações gráficas para examinar a distribuição das categorias e investigar possíveis associações com a classificação de crédito. Para complementar essa análise, são aplicados o teste Qui-quadrado de independência e o V de Cramér, que permitem avaliar a existência de associações estatísticas entre as variáveis categóricas e mensurar a intensidade dessas associações.

A análise é desenvolvida com o uso de Python e Power BI, ferramentas que permitem realizar os procedimentos estatísticos, explorar os dados, construir visualizações e comunicar os resultados de maneira clara e organizada.

Esta etapa tem caráter essencialmente descritivo e exploratório. Os resultados não estabelecem relações de causalidade nem, isoladamente, permitem prever a classificação de novos clientes. A construção e a avaliação de modelos de análise preditiva serão apresentadas separadamente na segunda parte do projeto.

2.Base de dados e variáveis

Os dados utilizados neste projeto correspondem ao conjunto German Credit, associado ao trabalho de Hans Hofmann, do Instituto de Estatística e Econometria da Universidade de Hamburgo, e disponibilizado no UCI Machine Learning Repository em 1994.

O conjunto de dados é composto por 1.000 observações e 21 variáveis. Cada linha representa um solicitante de crédito e contém informações financeiras, pessoais e relacionadas ao histórico de crédito.

Para a análise estatística, as variáveis foram classificadas de acordo com sua natureza e com a forma como são representadas na base de dados. O conjunto inclui variáveis quantitativas, variáveis qualitativas e uma variável de classificação, denominada classe_credito.

2.1. Descrição das variáveis

A Tabela 1 apresenta as variáveis utilizadas no projeto, seus tipos e uma descrição resumida de seu significado.

Tabela 1 – Descrição das variáveis do conjunto German Credit

Variável	Tipo	Descrição
idade	Quantitativa	Idade do solicitante
duracao	Quantitativa	Número de meses do crédito
valor_credito	Quantitativa	Valor monetário do crédito solicitado
numero_creditos	Quantitativa discreta	Número de créditos existentes
conta_corrente	Categórica ordinal	Situação da conta corrente
historico_credito	Categórica ordinal	Situação do histórico de crédito
finalidade	Categórica nominal	Finalidade para a qual o crédito foi solicitado
conta_poupanca	Categórica ordinal	Situação da poupança
tempo_emprego	Categórica ordinal	Tempo de permanência no emprego
taxa_parcela	Categórica ordinal	Proporção da parcela em relação à renda
fiador	Categórica nominal	Existência ou tipo de garantia/fiador
tempo_moradia	Categórica ordinal	Tempo de residência
patrimonio	Categórica ordinal	Situação patrimonial
tipo_moradia	Categórica nominal	Tipo de moradia
estado_civil_sexo	Categórica nominal	Categoria que combina estado civil e sexo
outros_creditos	Categórica nominal	Existência ou tipo de outros créditos
profissao	Categórica nominal	Categoria profissional

dependentes	Categórica discreta	Número de pessoas dependentes
telefone	Categórica nominal	Indicação da existência de telefone
trabalhador_estrangeiro	Categórica nominal	Indicação de trabalhador estrangeiro
classe_credito	Categórica binária	Classificação do crédito

Fonte: elaboração própria, com base no conjunto de dados German Credit.

A variável classe_credito representa a classificação do crédito e permite analisar a distribuição dos casos entre as categorias definidas na base. Na versão utilizada neste projeto, a codificação adotada é 0 para crédito bom e 1 para crédito ruim.

A natureza das variáveis orienta a escolha dos procedimentos estatísticos. As variáveis quantitativas podem ser descritas por medidas de posição e dispersão e por distribuições de frequência. As variáveis qualitativas podem ser examinadas por meio de frequências absolutas e relativas, gráficos e tabelas de contingência.

Nesta primeira parte do projeto, a análise concentra-se nas variáveis qualitativas e na investigação de possíveis associações com a classificação de crédito. Para isso, são utilizados procedimentos de Estatística Descritiva, análise gráfica e testes de associação, incluindo o teste Qui-quadrado de independência e o V de Cramér, conforme aplicável.

2.2. Visualização inicial dos dados

Após a leitura do conjunto de dados no Python, por meio do Google Colab, foi realizada uma inspeção inicial das observações e das variáveis. Essa etapa permite verificar a estrutura da base e familiarizar-se com os dados antes da realização das análises estatísticas.

Tabela 2 – Visualização inicial dos dados no Google Colab

Escolher arquivos german_credit_pt_1.csv

german_credit_pt_1.csv(text/csv) - 47072 bytes, last modified: 25/06/2026 - 100% done

Saving german_credit_pt_1.csv to german_credit_pt_1.csv

	conta_corrente	duracao	historico_credito	finalidade	valor_credito	conta_poupanca	tempo_emprego	taxa_parcela	estado_civil_s
0	1	18	4	2	1049	1	2	4	
1	1	9	4	0	2799	1	3	2	
2	2	12	2	9	841	2	4	2	
3	1	12	4	0	2122	1	3	3	
4	1	12	4	0	2171	1	3	4	

5 rows × 21 columns

Fonte: elaboração própria, a partir da leitura dos dados no Python, utilizando o Google Colab.

3. Análise das variáveis quantitativas com Python

Nesta seção, são analisadas as variáveis quantitativas selecionadas da base German Credit: duração do crédito (duracao), valor do crédito (valor_credito), idade (idade), número de créditos (numero_creditos) e número de dependentes (dependentes).

A análise utiliza medidas de estatística descritiva, histogramas e coeficientes de assimetria e curtose, com o objetivo de compreender a distribuição dos dados, sua variabilidade e suas principais características.

3.1 Medidas descritivas

A estatística descritiva permite sintetizar as características das variáveis por meio de medidas de tendência central, dispersão e posição. Nesta etapa, são examinados a quantidade de observações, a média, o desvio-padrão, os valores mínimo e máximo e os quartis das variáveis selecionadas.

As variáveis analisadas são:

- Duração do crédito (meses): duracao
- Valor do crédito: valor_credito
- Idade (anos): idade
- Número de créditos: numero_creditos
- Número de dependentes: dependentes

Figura 1 — Estatísticas descritivas das variáveis quantitativas

```
Variáveis quantitativas:
['duracao', 'valor_credito', 'idade', 'numero_creditos', 'dependentes']
```

	count	mean	std	min	25%	50%	75%	max	assimetria	curtose
duracao	1000.0	20.903	12.058814	4.0	12.0	18.0	24.00	72.0	1.094184	0.919781
valor_credito	1000.0	3271.248	2822.751760	250.0	1365.5	2319.5	3972.25	18424.0	1.949594	4.292481
idade	1000.0	35.542	11.352670	19.0	27.0	33.0	42.00	75.0	1.024712	0.620529
numero_creditos	1000.0	1.407	0.577654	1.0	1.0	1.0	2.00	4.0	1.272576	1.604439
dependentes	1000.0	1.845	0.362086	1.0	2.0	2.0	2.00	2.0	-1.909445	1.649274

Fonte: elaboração própria, a partir da análise da base German Credit no Google Colab.

A tabela apresenta as principais medidas descritivas das variáveis quantitativas, permitindo observar suas diferenças de escala, tendência central, dispersão e distribuição. A partir desses resultados, cada variável é examinada individualmente, considerando seus valores mínimos e máximos, suas médias e seus quartis.

3.1.1 Duração do crédito

A variável duração do crédito apresenta média de aproximadamente 21 meses, com valores entre 4 e 72 meses.

O primeiro quartil (Q1) é de 12 meses, indicando que 25% das observações apresentam duração de até esse valor. A mediana (Q2) é de 24 meses, enquanto o terceiro quartil (Q3) é de 34 meses. Assim, 75% dos contratos apresentam duração de até 34 meses, enquanto aproximadamente 25% apresentam prazos superiores.

Esses resultados indicam uma variação considerável nos prazos dos contratos, com observações de menor duração e também contratos com prazos mais longos, chegando a 72 meses.

3.1.2 Idade

A variável idade apresenta média de aproximadamente 35 anos, com valor mínimo de 19 anos e máximo de 75 anos.

O primeiro quartil é de 27 anos, indicando que 25% dos solicitantes têm idade de até esse valor. A mediana é de 33 anos, e o terceiro quartil é de 42 anos. Portanto, 75% dos solicitantes têm idade de até 42 anos, enquanto aproximadamente 25% apresentam idade superior.

Esses resultados mostram que a base contempla solicitantes de diferentes faixas etárias, com metade das observações situada entre 27 e 42 anos.

3.1.3 Valor do crédito

A variável valor do crédito apresenta média de aproximadamente 3.271,3 unidades monetárias, com valor mínimo de 250 e máximo de 18.424.

O terceiro quartil é de aproximadamente 3.972,25, indicando que 75% dos créditos apresentam valores de até esse montante, enquanto aproximadamente 25% apresentam valores superiores.

A mediana é de 2.319,50. A média superior à mediana sugere que os valores mais elevados contribuem para aumentar a média da distribuição. A diferença entre os valores mínimo e máximo também evidencia uma amplitude considerável nos montantes solicitados.

3.1.4 Número de créditos

A variável número de créditos apresenta valores entre 1 e 4.

O primeiro quartil (Q1) e a mediana (Q2) são iguais a 1, enquanto o terceiro quartil (Q3) é igual a 2. Isso indica que pelo menos 50% das observações apresentam valor igual a 1 e que 75% apresentam valores de até 2.

Observa-se, portanto, uma concentração nos menores valores da variável, embora existam solicitantes com até quatro créditos registra**dos.**

3.1.5 Número de dependentes

A variável dependentes apresenta valores entre 1 e 2. O primeiro quartil, a mediana e o terceiro quartil são iguais a 2 (Q1 = 2, Q2 = 2 e Q3 = 2)

A análise das frequências identificou 155 observações com valor 1, correspondentes a 15,5% do total, e 845 observações com valor 2, correspondentes a 84,5%, totalizando 1.000 registros.

A média da variável é de 1,845, resultado coerente com a predominância do valor 2. A igualdade entre os três quartis evidencia uma forte concentração das observações nesse valor.

A interpretação do significado dos valores 1 e 2 deve considerar a codificação adotada na base de dados. Portanto, sem confirmar essa codificação, os resultados são descritos como valores da variável, sem presumir que representem literalmente um ou dois filhos.

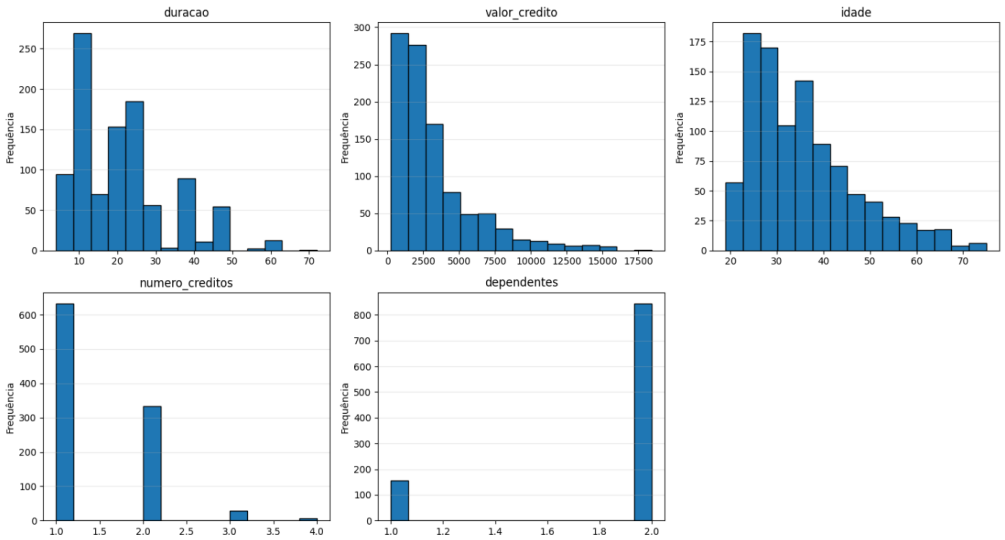
3.2 Distribuição das variáveis

A análise da distribuição das variáveis quantitativas permite observar como os valores estão organizados ao longo de sua faixa de variação, identificando regiões de maior concentração, dispersão e possíveis assimetrias. Para essa análise, foram utilizados histogramas e gráficos de distribuição gerados em Python, que permitem visualizar a frequência das observações em diferentes intervalos de valores.

Nesta etapa, são analisadas as distribuições das variáveis duração do crédito (duracao), idade (idade), valor do crédito (valor_credito), número de créditos (numero_creditos) e número de dependentes (dependentes).

A seguir, são apresentados os cinco gráficos gerados no Google Colab. A interpretação das distribuições será realizada individualmente e complementada, posteriormente, pela análise dos coeficientes de assimetria e curtose.

Figura 2 — Distribuição das variáveis quantitativas da base German Credit



Fonte: elaboração própria, a partir da análise da base German Credit no Google Colab.

A análise conjunta dos gráficos permite visualizar as características das distribuições e identificar diferenças na concentração e na dispersão dos valores. A seguir, cada variável é examinada individualmente, relacionando as características observadas nos gráficos com os resultados das medidas estatísticas descritivas.

3.2.1 Distribuição da duração do crédito

A distribuição apresenta maior concentração nos prazos mais curtos, com redução da frequência à medida que a duração aumenta. Observa-se também uma cauda à direita, indicando a presença de contratos com prazos mais longos.

3.2.2 Distribuição do valor do crédito

Observa-se maior concentração dos valores de crédito nas faixas de menor valor, com redução da frequência à medida que os montantes aumentam. A distribuição apresenta assimetria à direita, com alguns valores consideravelmente superiores aos mais frequentes.

3.2.3 Distribuição da idade

A distribuição da idade apresenta maior concentração aproximadamente entre 22 e 45 anos, conforme observado no gráfico. Também existem solicitantes em faixas etárias mais elevadas, chegando a 75 anos.

3.2.4 Distribuição do número de créditos

Observa-se concentração das observações no valor 1, com frequências menores para valores mais elevados. Esse comportamento é coerente com os quartis apresentados anteriormente.

3.2.5 Distribuição do número de dependentes

A distribuição apresenta forte concentração no valor 2, correspondente a 845 observações (84,5%), enquanto 155 observações (15,5%) apresentam valor 1. Esse resultado confirma a concentração identificada nas medidas descritivas.

3.3 Assimetria e curtose

Após a análise gráfica das distribuições, foram calculadas as medidas de **assimetria** e **curtose** das variáveis quantitativas, com o objetivo de complementar a interpretação dos histogramas e caracterizar numericamente a forma das distribuições.

Resultados

Variável	Assimetria	Curtose
Duração	1,094184	0,919700
Valor do crédito	1,949500	4,292491
Idade	1,024712	0,620529
Número de créditos	1,272576	1,604439
Dependentes	-1,909445	1,649274

Interpretação da assimetria

As variáveis **duração, valor do crédito, idade e número de créditos apresentam assimetria positiva**, com valores de 1,094, 1,950, 1,025 e 1,273, respectivamente. Esse resultado indica distribuições com caudas alongadas à direita, sugerindo a presença de observações com valores elevados em relação à região de maior concentração dos dados.

A variável **valor do crédito** apresenta a maior assimetria positiva (1,950), indicando uma distribuição acentuadamente assimétrica à direita. Esse resultado é coerente com a amplitude dos valores observados, de 250 a 18.424 unidades monetárias, e com o histograma, que mostra maior concentração nos valores mais baixos.

A variável **dependentes** apresenta assimetria negativa, com valor de -1,909. Esse resultado indica uma distribuição assimétrica, com maior concentração em valores elevados e uma cauda direcionada aos valores menores. Como essa variável assume apenas os valores 1 e 2, sua interpretação deve considerar a natureza discreta dos dados e a concentração observada no histograma.

Interpretação da curtose

Todas as variáveis apresentam **valores positivos de curtose**. Considerando que a medida utilizada seja o excesso de curtose, esses resultados indicam distribuições com excesso de curtose positivo em relação à distribuição normal.

O maior valor é observado para **valor do crédito (4,292)**, seguido por **dependentes (1,649)**, **número de créditos (1,604)**, **duração (0,920)** e **idade (0,621)**.

A variável **valor do crédito** apresenta o maior excesso de curtose, sugerindo maior peso relativo nas caudas em comparação com uma distribuição normal. Esse resultado complementa a análise do histograma e da amplitude dos valores observados. Entretanto, a curtose, isoladamente, não confirma a existência de observações atípicas; sua identificação exige uma análise específica.

As variáveis **duração** e **idade** também apresentam excesso de curtose positivo, embora com valores menores em comparação com o valor do crédito.

Em conjunto, as medidas de assimetria e curtose complementam a análise gráfica realizada anteriormente, permitindo descrever quantitativamente a forma das

distribuições e identificar características relevantes para as etapas seguintes da análise exploratória.

3.4 Análise da correlação entre as variáveis quantitativas

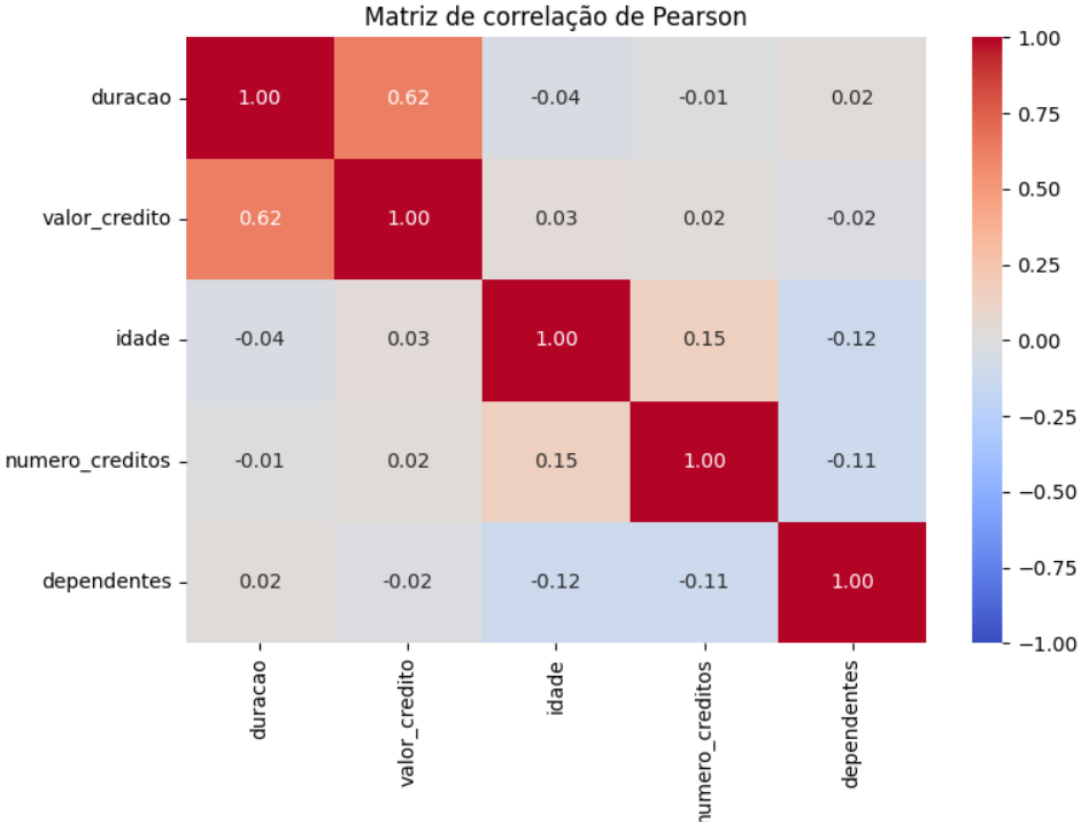
Para avaliar a associação entre as variáveis quantitativas do conjunto de dados German Credit, foram calculadas as matrizes de correlação de Pearson e de Spearman, considerando as variáveis duração do crédito, valor do crédito, idade, número de créditos e número de dependentes.

A utilização dessas duas medidas permite analisar tanto as associações lineares quanto as associações monotônicas entre as variáveis, complementando a análise exploratória dos dados.

3.4.1 Matriz de correlação de Pearson

O coeficiente de correlação de Pearson mede a intensidade e a direção da associação linear entre duas variáveis quantitativas. Seus valores variam entre −1 e +1: valores positivos indicam associação linear positiva, valores negativos indicam associação linear negativa e valores próximos de zero indicam pouca associação linear.

Tabela 3 – Matriz de correlação de Pearson



Fonte: Elaboração própria, com base no conjunto de dados German Credit.

O resultado que mais se destaca é a correlação positiva entre a duração e o valor do crédito, com coeficiente de r = 0,625. Essa associação, de magnitude moderada a relativamente forte, indica que valores de crédito mais elevados tendem a estar associados a prazos de pagamento mais longos.

As demais correlações apresentaram magnitudes baixas. A associação entre idade e número de créditos foi positiva, com r = 0,151), enquanto a correlação entre idade e número de dependentes foi negativa, com r = -0,119. Também foi observada uma associação negativa entre número de créditos e número de dependentes, com r = -0,110.

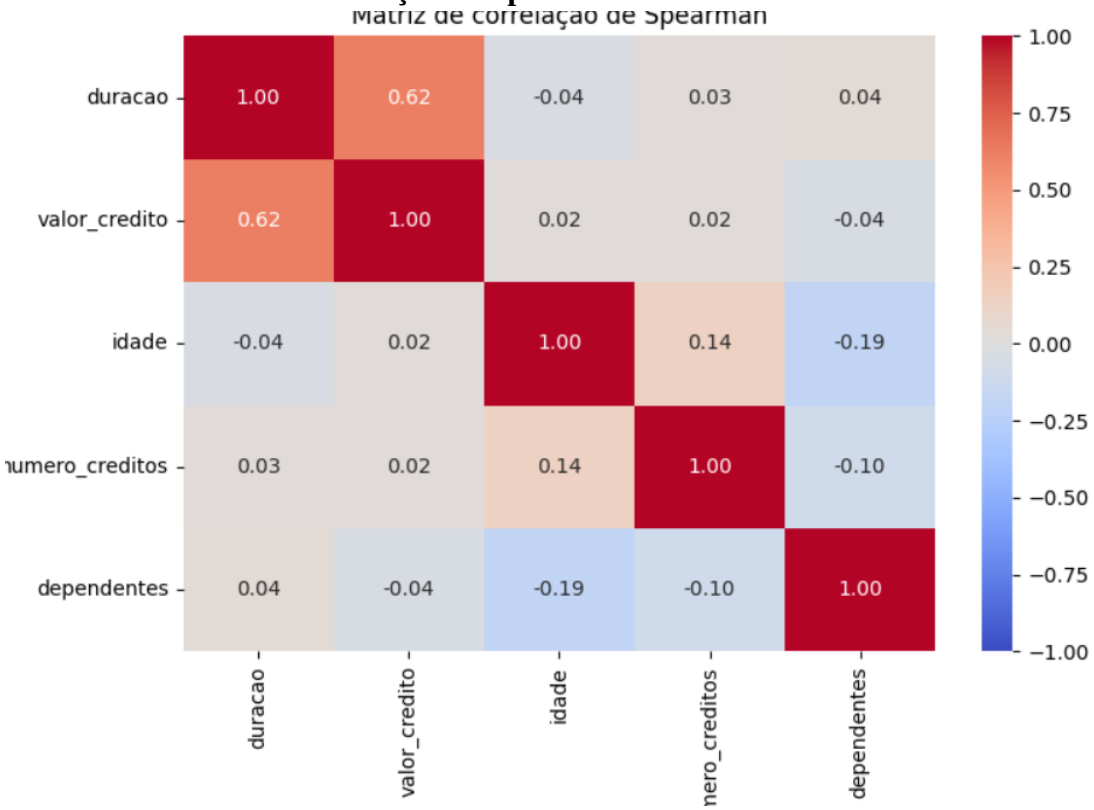
As demais associações apresentaram coeficientes próximos de zero, indicando pouca relação linear entre os respectivos pares de variáveis.

De modo geral, a matriz de Pearson evidencia que a associação linear mais expressiva ocorre entre duração e valor do crédito.

3.4.2 Matriz de correlação de Spearman

Como complemento, foi calculada a matriz de correlação de Spearman, uma medida não paramétrica baseada nos postos das observações. Diferentemente de Pearson, que avalia associações lineares, Spearman avalia a intensidade e a direção de associações monotônicas, permitindo identificar relações que não precisam ser estritamente lineares.

Tabela 4 – Matriz de correlação de Spearman



Fonte: Elaboração própria, com base no conjunto de dados German Credit.

Os resultados de Spearman confirmam a associação positiva entre duração e valor do crédito, com coeficiente r_s = 0,625). Esse resultado sugere que créditos de maior valor tendem a estar associados a prazos mais longos, mantendo-se a principal relação observada na análise de Pearson.

Entre as demais variáveis, destaca-se a correlação negativa entre idade e número de dependentes, com r_s = -0,191. Também foram observadas associações positivas de baixa magnitude entre idade e número de créditos, com r_s = 0,142), e negativas entre número de créditos e número de dependentes, com r_s = -0,097.

As demais correlações apresentaram magnitudes próximas de zero, indicando associações monotônicas pouco expressivas entre os respectivos pares de variáveis.

3.4.3 Comparação entre as matrizes de Pearson e Spearman

A comparação das duas matrizes revela resultados semelhantes para a maioria dos pares de variáveis. A principal associação, entre duração e valor do crédito, apresentou coeficientes praticamente iguais nas duas medidas: r = 0,625) para Pearson e r_s = 0,625 para Spearman.

Entretanto, algumas diferenças foram observadas. A associação entre idade e número de dependentes apresentou maior magnitude negativa em Spearman r_s = -0,191 do que em Pearson r = -0,119)). Essa diferença sugere que a intensidade da associação depende da medida utilizada, uma vez que os dois coeficientes avaliam aspectos distintos das relações entre as variáveis.

Em síntese, as duas análises destacam a associação entre duração e valor do crédito, enquanto as demais relações apresentam magnitudes relativamente baixas. Esses resultados contribuem para a compreensão das características do conjunto de dados e complementam a análise exploratória.

Ressalta-se que os coeficientes de correlação, isoladamente, não demonstram causalidade nem permitem afirmar a significância estatística das associações. Para avaliar a significância, seria necessário analisar os respectivos valores de *p* ou intervalos de confiança.

Conclusão da análise das variáveis quantitativas

A análise descritiva das variáveis quantitativas permitiu caracterizar o comportamento dos dados do conjunto *German Credit*, considerando medidas de tendência central e dispersão, distribuição, assimetria, curtose e relações entre as variáveis.

Os resultados evidenciaram comportamentos distintos quanto à variabilidade e à distribuição dos valores. O **valor do crédito** apresentou maior dispersão e assimetria,

indicando a presença de valores elevados em relação à região central da distribuição. A **duração do crédito** também apresentou amplitude considerável. A variável **idade** mostrou maior concentração dos valores em torno de sua região central, enquanto **número de créditos** e **número de dependentes** apresentaram menor variabilidade.

A análise das correlações evidenciou que a associação mais expressiva entre as variáveis quantitativas ocorre entre **duração e valor do crédito**, com coeficientes de aproximadamente 0,625 tanto para Pearson quanto para Spearman. Esse resultado indica uma associação positiva moderada a relativamente forte, sugerindo que prazos de crédito mais longos tendem a estar associados a valores de crédito mais elevados. As demais correlações apresentaram magnitudes baixas, indicando associações lineares ou monotônicas pouco expressivas entre a maioria dos pares de variáveis analisados.

De modo geral, a análise das variáveis quantitativas proporcionou uma visão inicial das características e das relações presentes no conjunto *German Credit*, contribuindo para a compreensão dos dados e estabelecendo uma base para a etapa seguinte do estudo, dedicada à análise das **variáveis qualitativas e de suas associações com a classificação de crédito**.

4. Análise exploratória das variáveis qualitativas

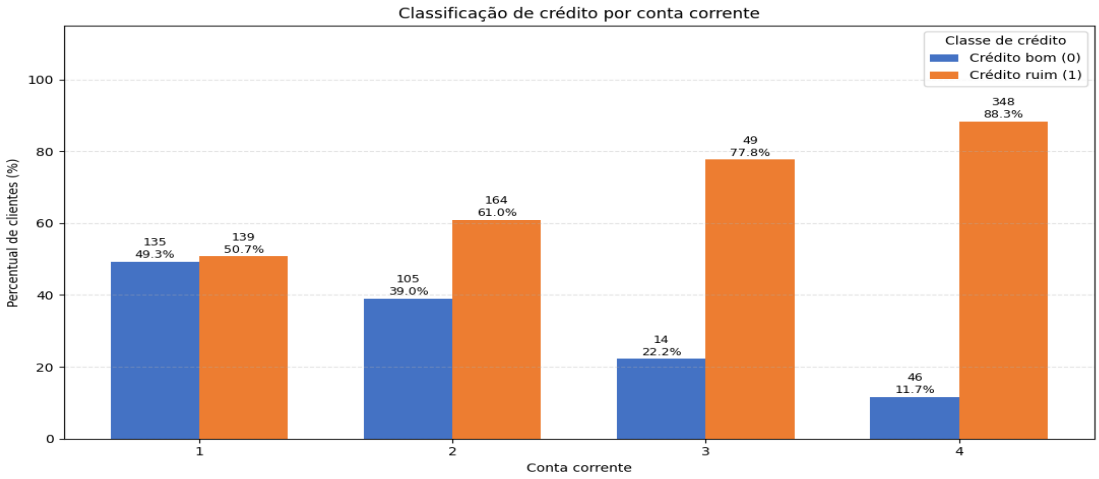
As variáveis qualitativas foram analisadas por meio de tabelas de contingência e gráficos de distribuição percentual, considerando sua relação com a variável-alvo classe_credito. O objetivo foi identificar diferenças na distribuição das classes de crédito entre as categorias das variáveis explicativas e reconhecer padrões relevantes para as etapas posteriores da análise estatística.

Na base de dados utilizada, a variável classe_credito apresenta duas categorias: **0 = crédito bom**, correspondente a 300 clientes (30% da amostra), e **1 = crédito ruim**, correspondente a 700 clientes (70% da amostra).

Para facilitar a comparação entre as categorias, foram calculadas as proporções de crédito bom e crédito ruim dentro de cada grupo, de modo que a soma dos percentuais das duas classes em cada categoria corresponda a 100%. Os gráficos foram posicionados antes das respectivas tabelas, permitindo uma visualização inicial dos resultados, seguida da apresentação dos valores absolutos e percentuais.

4.1 Conta corrente

Figura 3 – Distribuição da classe de crédito por categoria de conta corrente



Fonte: Elaboração própria, com base no conjunto de dados German Credit

Tabela 5– Distribuição da classe de crédito por categoria de conta corrente

Categoria	Crédito bom (0)	Crédito ruim (1)	Total	Crédito ruim (%)
1	135	139	274	50,7%
2	105	164	269	61,0%
3	14	49	63	77,8%
4	46	348	394	88,3%
Total	300	700	1.000	70,0%

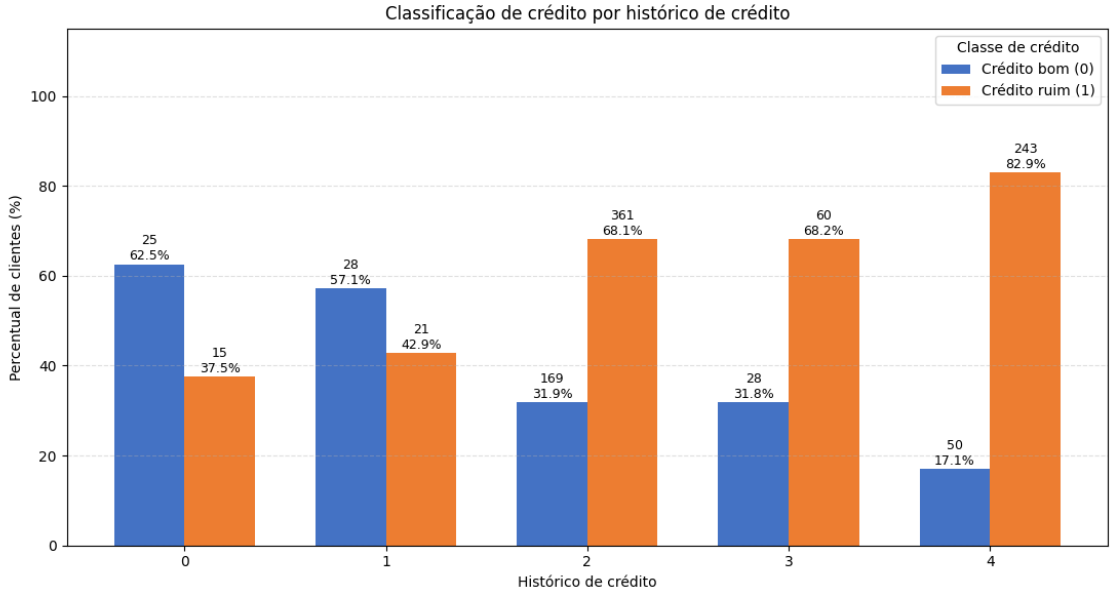
Fonte: Elaboração própria, com base no conjunto de dados German Credit.

Observa-se uma diferença expressiva entre as categorias. A categoria 1 apresenta 50,7% de crédito ruim, enquanto a categoria 4 apresenta 88,3%. A proporção de crédito ruim aumenta entre as categorias apresentadas, embora a interpretação econômica dos códigos dependa da documentação original da base.

Os resultados sugerem uma associação entre a categoria de conta corrente e a classificação de crédito, aspecto que será examinado formalmente pelo teste do qui-quadrado e pelo V de Cramér

4.2 Histórico de crédito

Figura 4 – Distribuição da classe de crédito por categoria de histórico de crédito



Fonte: Elaboração própria, com base no conjunto de dados German Credit.

Tabela 6 – Distribuição da classe de crédito por categoria de histórico de crédito

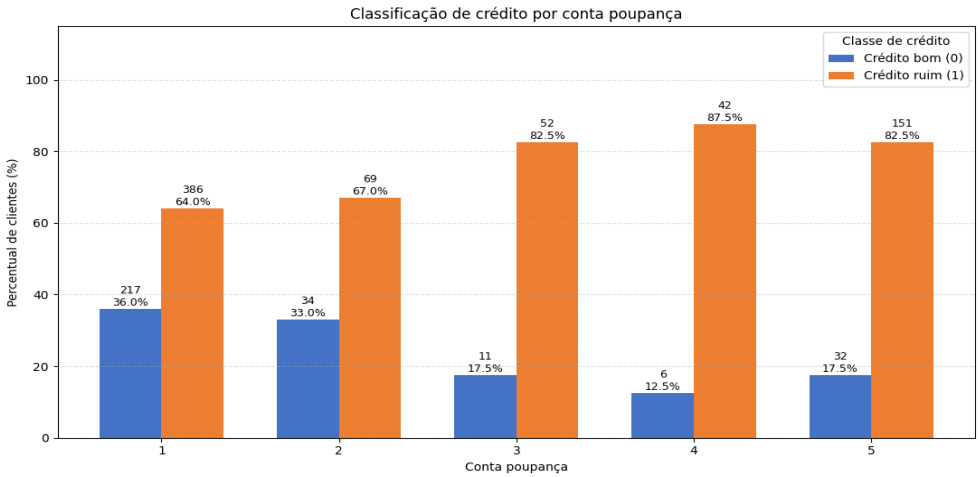
Categoria	Crédito bom (0)	Crédito ruim (1)	Total	Crédito ruim (%)
0	25	15	40	37,5%
1	28	21	49	42,9%
2	169	361	530	68,1%
3	28	60	88	68,2%
4	50	243	293	82,9%
Total	300	700	1.000	70,0%

Fonte: Elaboração própria, com base no conjunto de dados German Credit.

A categoria 4 apresenta a maior proporção de crédito ruim, com 82,9%, enquanto as categorias 0 e 1 apresentam proporções de 37,5% e 42,9%, respectivamente. As diferenças observadas indicam que a distribuição da classe de crédito varia entre as categorias de histórico de crédito.

4.3 Conta poupança

Figura 5 – Distribuição da classe de crédito por Conta poupança



Fonte: Elaboração própria, com base no conjunto de dados German Credit.

Tabela 7 – Distribuição da classe de crédito por categoria de conta poupança

Categoria	Crédito bom (0)	Crédito ruim (1)	Total	Crédito ruim (%)
1	217	386	603	64,0%
2	34	69	103	67,0%
3	11	52	63	82,5%
4	6	42	48	87,5%
5	32	151	183	82,5%
Total	300	700	1.000	70,0%

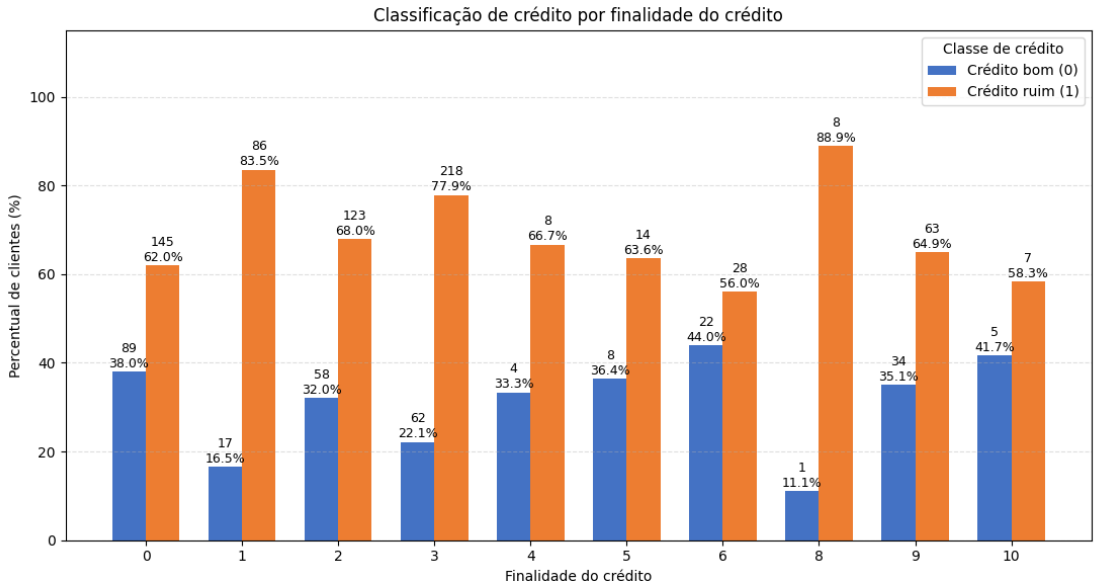
Fonte: Elaboração própria, com base no conjunto de dados German Credit.

As categorias 3, 4 e 5 apresentam proporções de crédito ruim superiores à média geral de 70%. A categoria 4 registra a maior proporção, de 87,5%, seguida pelas categorias 3 e 5, ambas com 82,5%.

Esses resultados mostram diferenças na distribuição da classificação de crédito entre as categorias de conta poupança. Entretanto, a magnitude dessas diferenças e sua significância estatística devem ser avaliadas conjuntamente com os testes de associação.

4.4 Finalidade do crédito

Figura 6 – Distribuição da classe de crédito por finalidade



Fonte: Elaboração própria, com base no conjunto de dados German Credit.

Tabela 8 – Distribuição da classe de crédito por finalidade do crédito

Categoria	Crédito bom (0)	Crédito ruim (1)	Total	Crédito ruim (%)
0	89	145	234	62,0%
1	17	86	103	83,5%
2	58	123	181	68,0%
3	62	218	280	77,9%
4	4	8	12	66,7%
5	8	14	22	63,6%
6	22	28	50	56,0%
8	1	8	9	88,9%
9	34	63	97	64,9%
10	5	7	12	58,3%
Total	300	700	1.000	70,0%

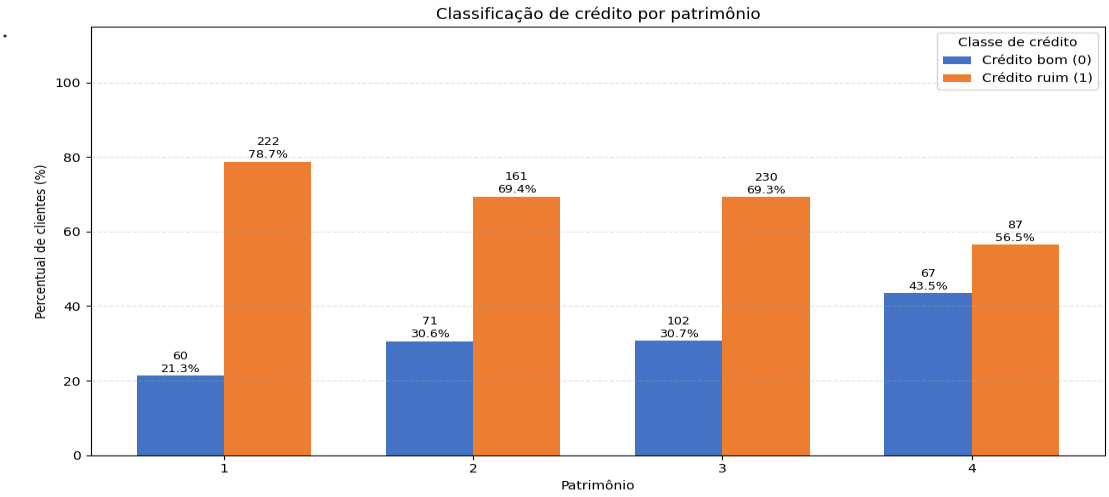
Fonte: Elaboração própria, com base no conjunto de dados German Credit.

A proporção de crédito ruim varia entre as categorias de finalidade. A categoria 8 apresenta a maior proporção, de 88,9%, seguida pela categoria 1, com 83,5%. Por outro lado, a categoria 6 apresenta a menor proporção, de 56,0%.

É importante interpretar esses percentuais com cautela, pois algumas categorias possuem poucas observações. A categoria 8, por exemplo, contém apenas nove registros, dos quais oito correspondem a crédito ruim. Portanto, sua proporção elevada não deve ser interpretada isoladamente como evidência de um padrão estável.

4.5 Patrimônio

Figura 7 – Distribuição da classe de crédito por patrimonio



Fonte: Elaboração própria, com base no conjunto de dados German Credit

Tabela 9 – Distribuição da classe de crédito por categoria de patrimônio

Categoria	Crédito bom (0)	Crédito ruim (1)	Total	Crédito ruim (%)
1	60	222	282	78,7%
2	71	161	232	69,4%
3	102	230	332	69,3%
4	67	87	154	56,5%
Total	300	700	1.000	70,0%

Fonte: Elaboração própria, com base no conjunto de dados German Credit.

A categoria 1 apresenta 78,7% de crédito ruim, enquanto a categoria 4 apresenta 56,5%. As categorias 2 e 3 apresentam proporções próximas de 69,4% e 69,3%, respectivamente.

Os resultados indicam diferenças na distribuição da classe de crédito entre as categorias de patrimônio. Contudo, a interpretação econômica dessas diferenças depende dos significados atribuídos aos códigos na documentação original da base.

4.6 Síntese da análise das variáveis qualitativas

A análise descritiva das tabelas cruzadas e dos gráficos revelou diferenças na distribuição das classes de crédito entre as categorias das cinco variáveis qualitativas examinadas.

As variáveis conta corrente e conta poupança apresentaram diferenças expressivas nas proporções de crédito bom e crédito ruim entre suas categorias. Histórico de crédito, finalidade do crédito e patrimônio também evidenciaram variações na distribuição dessas classes.

Esses resultados permitem identificar padrões de distribuição e possíveis associações entre as características dos clientes e sua classificação de crédito. Entretanto, por se tratarem de observações descritivas, não permitem afirmar, isoladamente, que as associações são estatisticamente significativas nem que as variáveis possuem capacidade preditiva.

5. Teste do qui-quadrado e V de Cramér

Para avaliar a associação entre as variáveis categóricas e a classe de crédito, foram utilizados o teste do qui-quadrado de independência e o V de Cramér.

O teste do qui-quadrado permite avaliar se existem evidências estatísticas de associação entre duas variáveis categóricas. O V de Cramér, por sua vez, mede a intensidade dessa associação, assumindo valores entre 0 e 1. Valores mais próximos de zero indicam associações de menor intensidade, enquanto valores mais elevados indicam associações relativamente mais intensas.

Os dois indicadores devem ser interpretados conjuntamente. O valor-p fornece evidências para avaliar a hipótese de independência entre as variáveis, enquanto o V de Cramér indica a intensidade da associação observada. Assim, uma associação estatisticamente significativa não é necessariamente uma associação de grande intensidade.

5.1 Resultados dos testes

A Tabela 8 apresenta os resultados do teste do qui-quadrado de independência e do V de Cramér para as variáveis qualitativas analisadas em relação à classe de crédito.

Tabela 9 – Resultados do teste do qui-quadrado e do V de Cramér

Variável	V de Cramér	Valor-p	Interpretação
Conta corrente	0,352	< 0,001	Maior associação observada
Histórico de crédito	0,248	< 0,001	Segunda maior associação
Conta poupança	0,190	< 0,001	Associação de menor intensidade
Finalidade	0,183	< 0,001	Associação de menor intensidade
Patrimônio	0,154	< 0,001	Associação de menor intensidade
Tipo de moradia	0,137	< 0,001	Associação de menor intensidade
Tempo de emprego	0,136	0,001	Associação de menor intensidade
Outros créditos	0,113	0,002	Associação de menor intensidade
Estado civil e sexo	0,098	0,022	Associação de menor intensidade
Fiador	0,082	0,036	Associação de menor intensidade
Trabalhador estrangeiro	0,076	0,016	Associação de menor intensidade
Profissão	0,043	0,597	Não significativa a 5%
Telefone	0,034	0,279	Não significativa a 5%

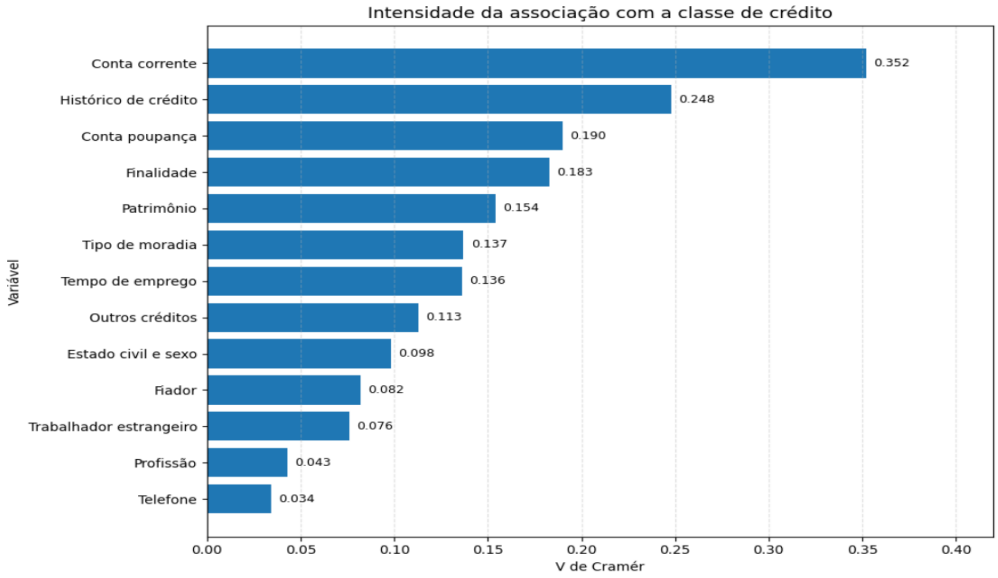
Fonte: elaboração própria com base nos resultados dos testes estatísticos.

Os resultados indicam que, entre as variáveis analisadas, conta corrente apresentou a maior intensidade de associação com a classe de crédito, com V de Cramér igual a 0,352. Em seguida, destaca-se histórico de crédito, com valor de 0,248. As demais variáveis apresentaram valores inferiores, indicando associações de menor intensidade relativa.

Considerando o nível de significância de 5%, dez das treze variáveis apresentaram valores-p inferiores a 0,05, fornecendo evidências estatísticas de associação com a classificação de crédito. Por outro lado, profissão ($p = 0,597$) e telefone ($p = 0,279$) não apresentaram evidências estatísticas suficientes para rejeitar a hipótese de independência nesse nível de significância.

É importante destacar que a significância estatística não implica, necessariamente, uma associação de grande intensidade. Esse aspecto pode ser observado, por exemplo, nas variáveis trabalhador estrangeiro e fiador, que apresentaram valores-p inferiores a 0,05, mas valores de V de Cramér relativamente baixos.

Figura 8 – V de Cramér das variáveis categóricas em relação à classe de crédito.



Fonte: elaboração própria com base nos resultados dos testes estatísticos.

5.2 Interpretação dos resultados

A variável conta_corrente apresenta o maior V de Cramér entre as variáveis analisadas, com valor de 0,352, seguida por historico_credito (0,248), conta_poupanca (0,190) e finalidade (0,183). Esses resultados indicam que a distribuição das classes de crédito apresenta diferenças entre as categorias dessas variáveis, especialmente no caso de conta_corrente, que apresentou a associação de maior intensidade relativa.

Entretanto, o teste do qui-quadrado e o V de Cramér, isoladamente, não permitem estabelecer relações de causalidade nem determinar a capacidade preditiva de cada variável.

Considerando o nível de significância de 5%, a maioria das variáveis avaliadas apresentou valores-p inferiores a 0,05, indicando evidências estatísticas de associação com a classe de crédito. Em contrapartida, as variáveis profissão e telefone apresentaram valores-p superiores a 0,05. Portanto, nesses casos, não há evidências estatísticas suficientes para rejeitar a hipótese de independência entre as variáveis.

A ausência de significância estatística não significa necessariamente que essas variáveis sejam inúteis para a previsão da classe de crédito. Sua contribuição deverá ser avaliada posteriormente, na etapa de modelagem preditiva, considerando o desempenho dos modelos e procedimentos adequados de validação.

6. Análise dos resíduos padronizados de Pearson

Para aprofundar a análise das associações identificadas pelo teste do qui-quadrado de independência e pelo V de Cramér, foram calculados os resíduos padronizados de Pearson para cinco variáveis categóricas que apresentaram os maiores valores de V de

Cramér: conta corrente, histórico de crédito, conta poupança, finalidade do crédito e patrimônio.

Os resíduos padronizados permitem identificar as categorias cujas frequências observadas diferem das frequências esperadas sob a hipótese de independência entre a variável analisada e a classe de crédito. Valores positivos indicam frequências observadas superiores às esperadas, enquanto valores negativos indicam frequências inferiores às esperadas. Como referência exploratória, foram destacadas as categorias que apresentaram pelo menos um resíduo com valor absoluto igual ou superior a 2. Esse critério permite identificar desvios relativamente expressivos, mas não substitui testes específicos por categoria nem considera, por si só, os efeitos de múltiplas comparações.

6.1 Principais resultados

Tabela 9 – Resíduos padronizados de Pearson das categorias selecionadas

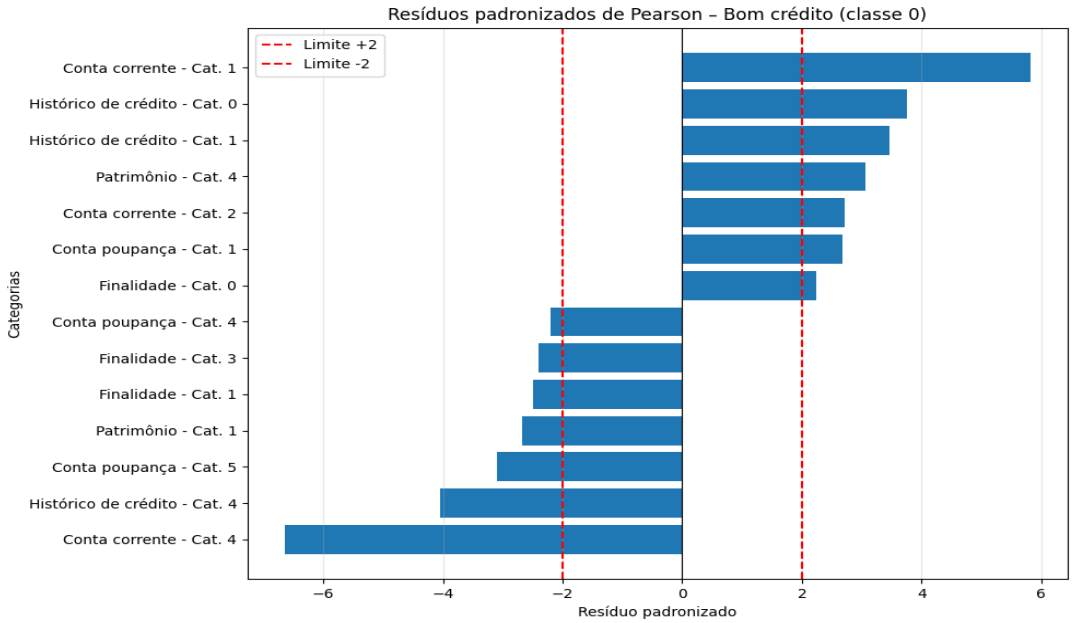
Variável	Categoria	Crédito bom (0)	Crédito ruim (1)
Conta corrente	1	5,82	−3,81
Conta corrente	2	2,71	−1,77
Conta corrente	4	−6,64	4,35
Histórico de crédito	0	3,75	−2,46
Histórico de crédito	1	3,47	−2,27
Histórico de crédito	4	−4,04	2,65
Conta poupança	1	2,68	−1,76
Conta poupança	4	−2,21	1,45
Conta poupança	5	−3,09	2,02
Finalidade do crédito	0	2,24	−1,47
Finalidade do crédito	1	−2,50	1,64
Finalidade do crédito	3	−2,40	1,57
Patrimônio	1	−2,67	1,75
Patrimônio	4	3,06	−2,00

Fonte: elaboração própria com base nos resultados obtidos no Python.

A Tabela 9 apresenta os resíduos padronizados de Pearson das categorias selecionadas nas cinco variáveis analisadas. Foram incluídas as categorias que apresentaram pelo menos um resíduo com valor absoluto igual ou superior a 2.

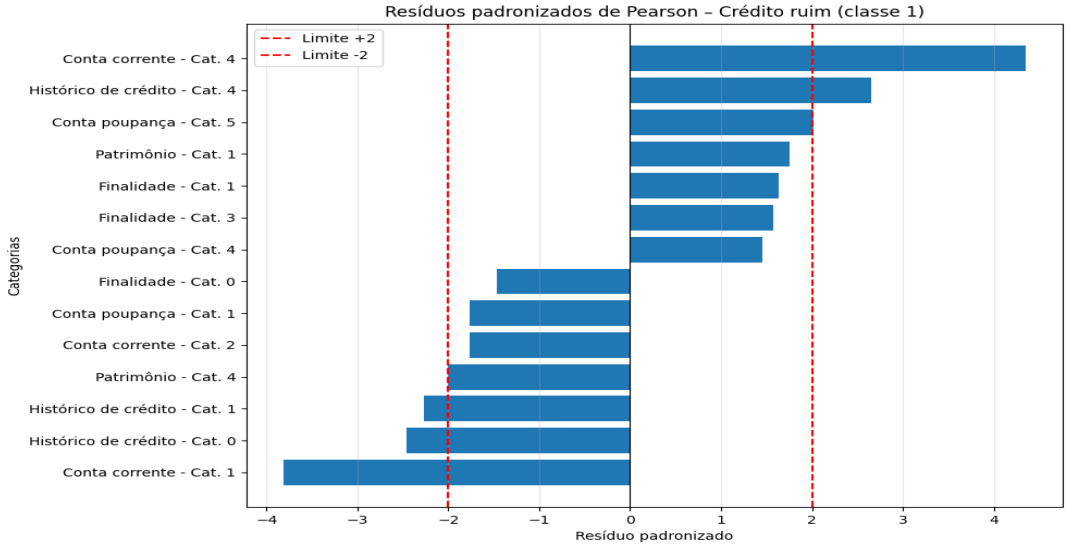
Para facilitar a interpretação dos resultados, os resíduos também serão apresentados graficamente, permitindo visualizar os desvios positivos e negativos em relação às frequências esperadas.

Figura 9 – Resíduos padronizados de Pearson da classe de crédito bom (classe 0).



Fonte: elaboração própria com base nos resultados obtidos no Python.

Figura 10 – Resíduos padronizados de Pearson da classe de crédito ruim (classe 1).



Fonte: elaboração própria com base nos resultados obtidos no Python.

6.2 Interpretação dos resultados

A variável **conta corrente** apresentou os desvios mais expressivos em relação às frequências esperadas. Na categoria 1, observou-se um resíduo positivo para clientes bons

(5,82) e negativo para clientes ruins (−3,81), indicando uma frequência de clientes bons superior e de clientes ruins inferior à esperada sob a hipótese de independência. A categoria 2 também apresentou resíduo positivo para clientes bons (2,71). Na categoria 4, ocorreu o padrão inverso, com resíduos de −6,64 para clientes bons e 4,35 para clientes ruins. Esses resultados evidenciam diferenças expressivas na distribuição das classes de crédito entre essas categorias.

No **histórico de crédito**, destacaram-se as categorias 0, 1 e 4. As categorias 0 e 1 apresentaram resíduos positivos para clientes bons (3,75 e 3,47, respectivamente) e negativos para clientes ruins (−2,46 e −2,27). Já a categoria 4 apresentou o padrão inverso, com resíduo negativo para clientes bons (−4,04) e positivo para clientes ruins (2,65). Esses resultados indicam diferenças na distribuição das classes de crédito entre as categorias analisadas.

Na variável **conta poupança**, a categoria 1 apresentou resíduo positivo para clientes bons (2,68), indicando frequência superior à esperada para essa classe. Por outro lado, as categorias 4 e 5 apresentaram resíduos negativos para clientes bons (−2,21 e −3,09, respectivamente) e positivos para clientes ruins (1,45 e 2,02). A categoria 5 apresentou o desvio mais expressivo entre essas duas categorias.

Quanto à variável **finalidade do crédito**, as categorias 0, 1 e 3 apresentaram desvios relevantes. A categoria 0 apresentou resíduo positivo para clientes bons (2,24), enquanto as categorias 1 e 3 apresentaram resíduos negativos para essa classe (−2,50 e −2,40, respectivamente). Esses resultados indicam diferenças nas frequências observadas, principalmente para a classe de clientes bons.

Por fim, na variável **patrimônio**, a categoria 1 apresentou resíduo negativo para clientes bons (−2,67) e positivo para clientes ruins (1,75). Na categoria 4, observou-se o padrão inverso, com resíduo positivo para clientes bons (3,06) e negativo para clientes ruins (−2,00). Essas categorias também apresentaram diferenças relevantes em relação às frequências esperadas.

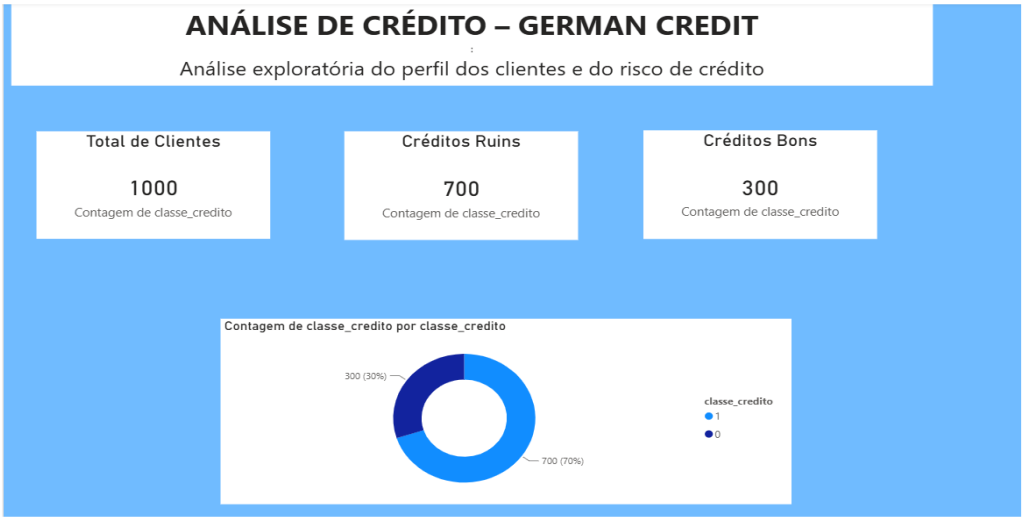
Em conjunto, os resultados complementam o teste do qui-quadrado e o V de Cramér, permitindo identificar as categorias que mais se destacam nos padrões de associação observados. As diferenças identificadas representam associações estatísticas e não permitem estabelecer relações de causalidade. Além disso, como foram examinadas diversas categorias, os resíduos devem ser interpretados como indicadores exploratórios, e não como evidência definitiva de significância estatística individual.

Cabe destacar que os números das categorias foram mantidos conforme a codificação utilizada no conjunto de dados. Sua interpretação substantiva depende da consulta ao dicionário de dados do German Credit.

7. Visualização e Análise dos Dados com Power BI

7.1 Visão Geral do German Credit

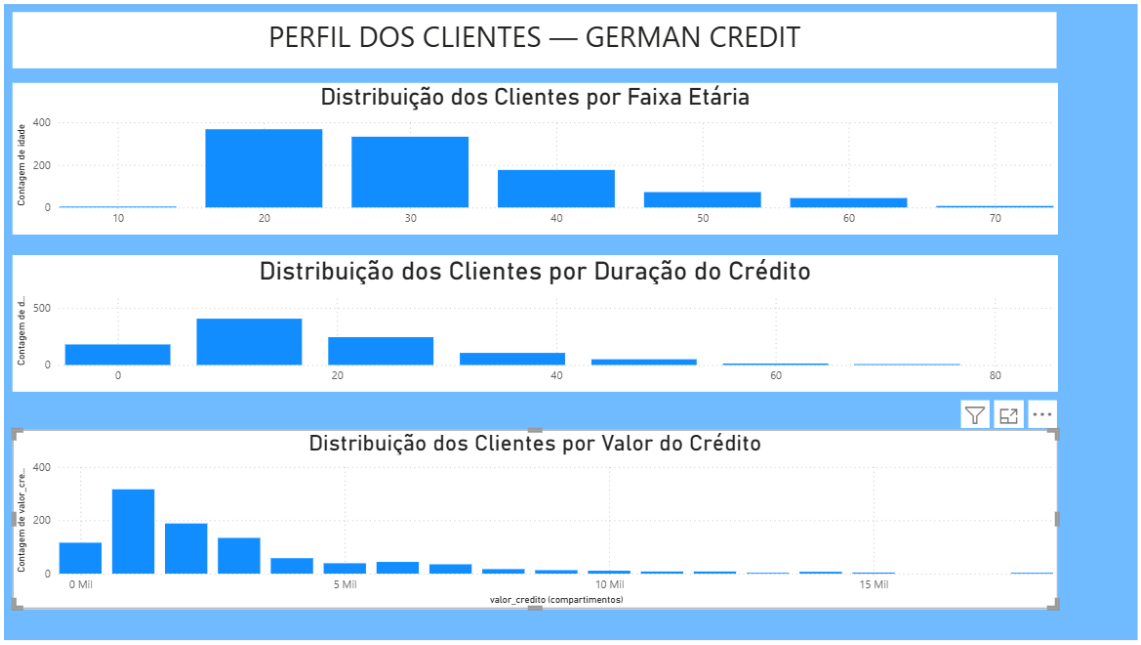
Figura 11: Visão Geral do German Credit



Fonte: Elaborado pela autora (2026).

7.2 Perfil dos Clientes

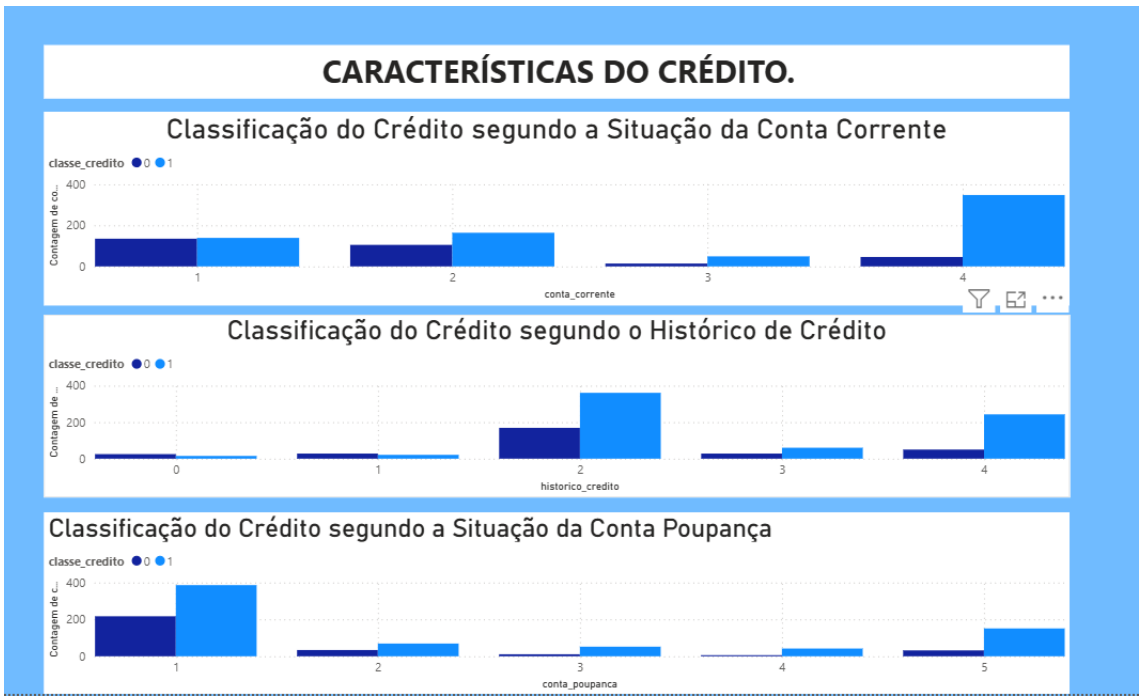
Figura 12: Perfil dos Clientes por faixa etária



Fonte: Elaborado pela autora (2026).

7.3 Características do Crédito

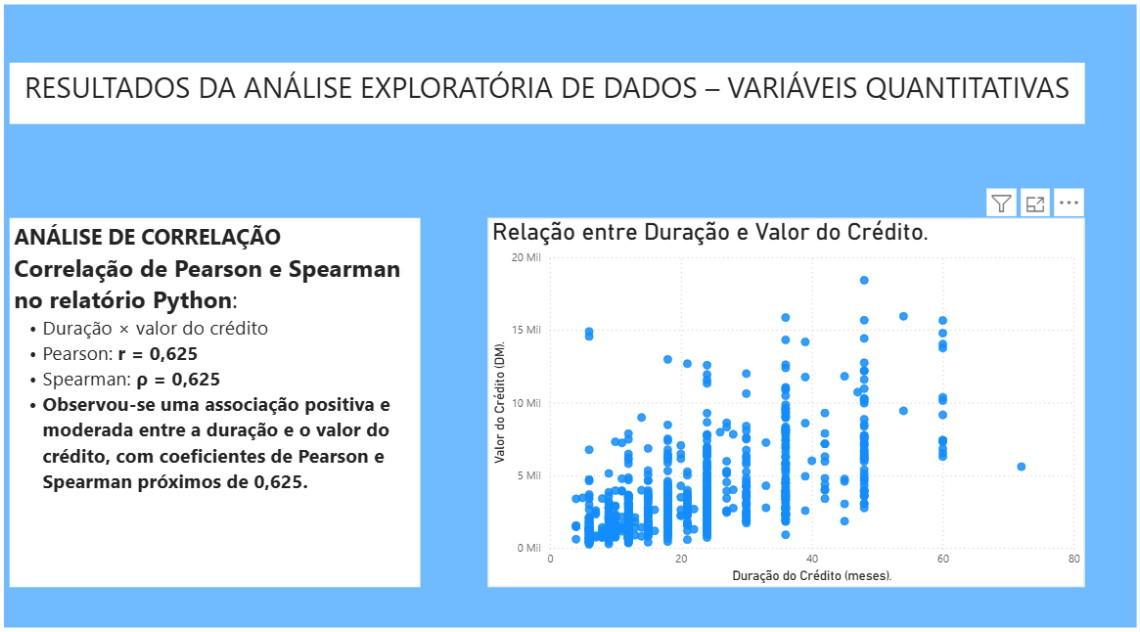
Figura 13: Características do Crédito



Fonte: Elaborado pela autora (2026).

7.4 Análise Exploratória de Variáveis Quantitativas

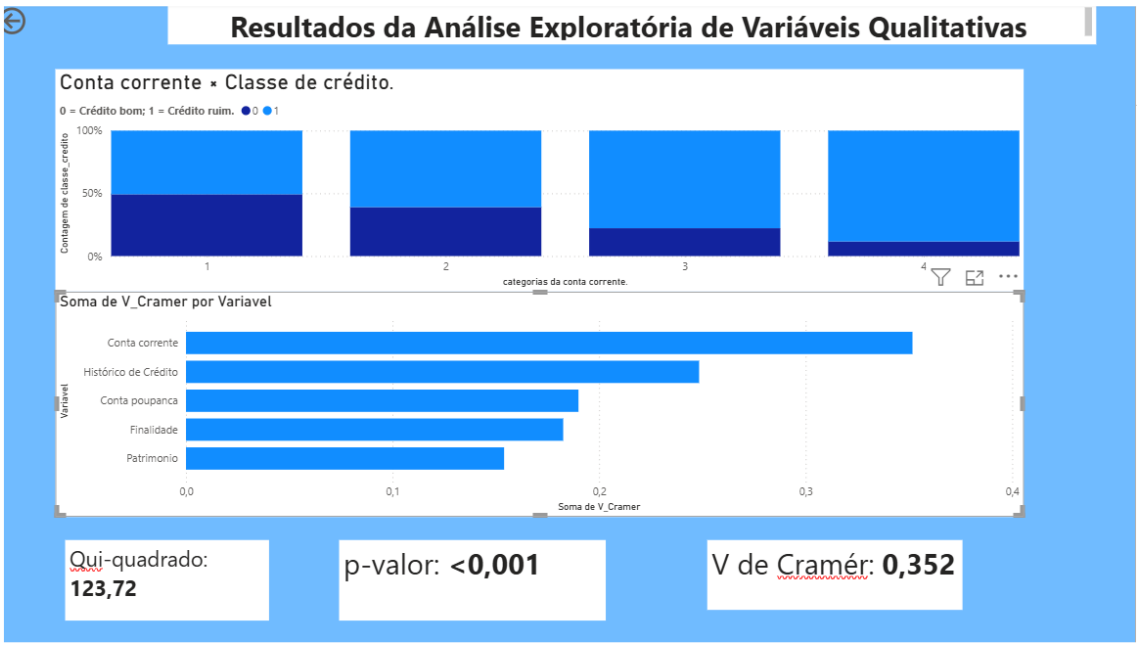
Figura 14: Análise Exploratória de Variáveis Quantitativas



Fonte: Elaborado pela autora (2026).

7.5 Análise Exploratória de Variáveis Qualitativas

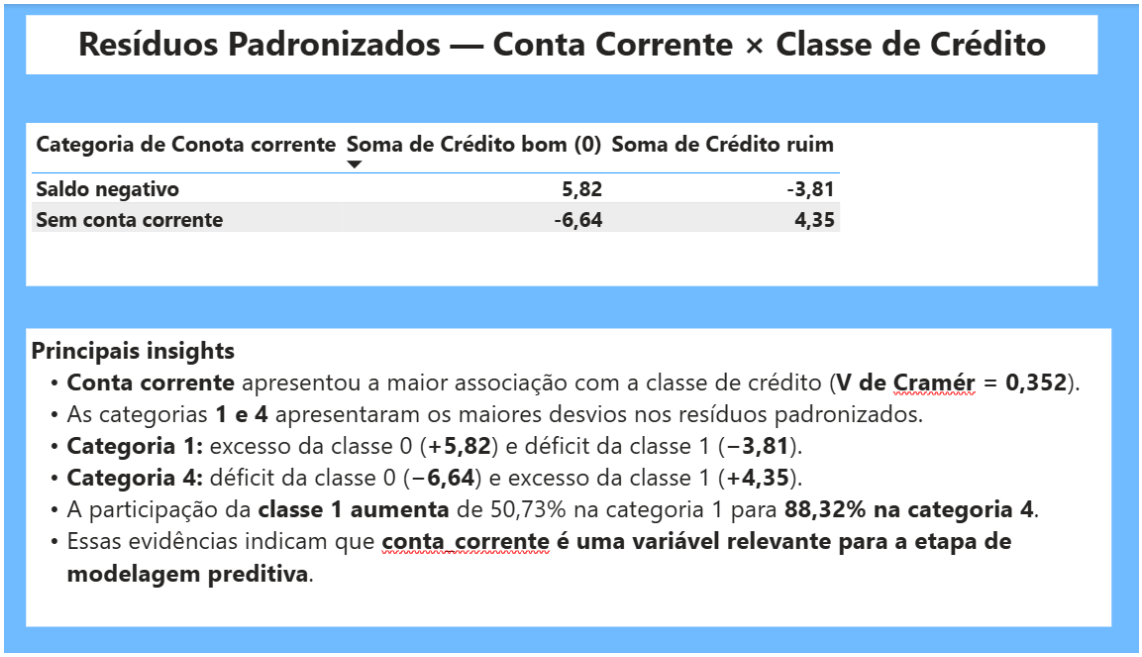
Figura 15: Análise Exploratória de Variáveis Qualitativas



Fonte: Elaborado pela autora (2026).

7.6 Análise de Resíduos

Figura 16: Análise de Resíduos



Fonte: Elaborado pela autora (2026).

8. Principais conclusões da análise exploratória

A análise exploratória da base German Credit permitiu identificar aspectos relevantes sobre a estrutura dos dados, a distribuição das variáveis e as associações entre as características dos clientes e a classe de crédito. Os principais resultados são apresentados a seguir.

1. Estrutura dos dados: a base contém 1.000 registros, 20 variáveis preditoras e uma variável-alvo, totalizando 21 colunas.
2. Qualidade dos dados: não foram identificados valores ausentes nas 21 colunas analisadas.
3. Distribuição da classe: 30% dos registros pertencem à classe de crédito bom (classe 0), enquanto 70% pertencem à classe de crédito ruim (classe 1). Essa distribuição evidencia um desequilíbrio entre as classes.
4. Variáveis quantitativas: o valor do crédito apresenta assimetria positiva expressiva, enquanto a duração do crédito também apresenta distribuição assimétrica à direita.
5. Correlação: a associação linear mais forte identificada entre as variáveis quantitativas ocorre entre duração e valor do crédito, com coeficiente de correlação de Pearson igual a 0,625.
6. Variáveis categóricas: as análises das tabelas de contingência indicaram diferenças na distribuição das classes de crédito entre categorias de conta corrente, histórico de crédito, conta poupança, finalidade do crédito e patrimônio.
7. Associação estatística: entre as variáveis categóricas avaliadas, conta corrente apresentou o maior valor do V de Cramér (0,352), seguida por histórico de crédito (0,248), conta poupança (0,190), finalidade do crédito (0,183) e patrimônio (0,154).
8. Análise dos resíduos: os resíduos padronizados de Pearson permitiram identificar categorias cujas frequências observadas se afastam das frequências esperadas sob a hipótese de independência. Os desvios mais expressivos foram observados principalmente em categorias de conta corrente e histórico de crédito, complementando os resultados do teste do qui-quadrado e do V de Cramér.
9. Próximos passos: os resultados exploratórios servirão de base para a etapa de modelagem preditiva, na qual serão avaliados o desempenho dos modelos e sua capacidade de discriminar as classes de crédito. As associações observadas nesta etapa não garantem, por si só, capacidade preditiva.

9. Limitações da análise

Esta etapa apresenta algumas limitações que devem ser consideradas na interpretação dos resultados:

- Os códigos das variáveis categóricas precisam ser interpretados com base na documentação da base original.
- A análise de correlação de Pearson identifica relações lineares e não abrange todas as formas possíveis de associação.
- As tabelas de contingência e os testes de associação descrevem relações estatísticas, mas não demonstram causalidade.
- Algumas categorias apresentam poucos registros, o que pode tornar as frequências e percentagens menos estáveis.
- A seleção das variáveis categóricas para a análise dos resíduos concentrou-se naquelas que apresentaram os maiores valores de V de Cramér.
- A importância preditiva das variáveis só poderá ser avaliada de forma mais completa durante a construção e validação dos modelos.

10. Próxima etapa do projeto

Após a conclusão da análise exploratória, a próxima etapa será desenvolver e avaliar um modelo de classificação por regressão logística.

O processo deverá incluir:

- preparação das variáveis para o modelo;
- separação dos dados em conjuntos de treinamento e teste;
- treinamento do modelo de regressão logística;
- análise e interpretação dos coeficientes estimados;
- avaliação do desempenho por meio da matriz de confusão, precisão, recall, F1-score, acurácia e área sob a curva ROC (ROC-AUC);
- análise dos resultados e das limitações do modelo.

Posteriormente, poderá ser realizada uma comparação com outros algoritmos de classificação, como árvore de decisão, para verificar possíveis diferenças de desempenho e interpretabilidade.

11. Conclusão final

A análise exploratória constituiu uma etapa fundamental para compreender a estrutura, a qualidade e as características da base German Credit antes da aplicação de modelos de classificação.

Os resultados evidenciaram diferenças na distribuição da classe de crédito entre categorias de algumas variáveis financeiras e pessoais. Entre as variáveis categóricas analisadas, conta corrente e histórico de crédito destacaram-se pelos maiores valores do V de Cramér. A análise dos resíduos padronizados de Pearson permitiu aprofundar esses resultados, identificando categorias cujas frequências observadas diferiram das frequências esperadas sob a hipótese de independência.

Entre as variáveis quantitativas, a associação linear mais expressiva ocorreu entre duração e valor do crédito, com coeficiente de correlação de Pearson igual a 0,625.

Em conjunto, os resultados fornecem uma compreensão inicial dos dados e orientam a continuidade do estudo. Na Parte II, será desenvolvida a modelagem preditiva por meio da regressão logística, com o objetivo de avaliar a capacidade do modelo de distinguir clientes de crédito bom e ruim. Essa avaliação permitirá verificar em que medida os padrões identificados na análise exploratória contribuem para a capacidade preditiva do modelo.

==========

APÊNDICE A – CÓDIGO PYTHON

ANÁLISE EXPLORATÓRIA DE DADOS – GERMAN CREDIT

==========

---

1. IMPORTAÇÃO DAS BIBLIOTECAS E CARREGAMENTO DOS DADOS

```
import pandas as pd import numpy as np import matplotlib.pyplot as plt import seaborn as sns

from google.colab import files from scipy.stats import chi2_contingency from sklearn.preprocessing import StandardScaler

uploaded = files.upload()

df = pd.read_csv('german_credit_pt_1.csv')

display(df.head())
```

Conferência da classificação de crédito

```
print("Distribuição da classe de crédito:") print(df['classe_credito'].value_counts().sort_index())

assert set(df['classe_credito'].dropna().unique()) == {0, 1} assert (df['classe_credito'] == 0).sum() == 300 assert (df['classe_credito'] == 1).sum() == 700

print("\nCodificação confirmada:") print("0 = Crédito bom") print("1 = Crédito ruim")
```

==========

2. ANÁLISE DAS VARIÁVEIS QUANTITATIVAS

==========

```
variaveis_quant = [ 'duracao', 'valor_credito', 'idade', 'numero_creditos', 'dependentes' ]

dados_quant = df[variaveis_quant].copy()
```

2.1 Estatísticas descritivas

```
estatisticas = dados_quant.describe().T

estatisticas['assimetria'] = dados_quant.skew() estatisticas['curtose'] = dados_quant.kurtosis()
```

```
display(estatisticas)
```

2.2 Histogramas

```
fig, axes = plt.subplots(3, 2, figsize=(13, 8))
for i, var in enumerate(variaveis_quant):
ax = axes.flat[i]

ax.hist(
    dados_quant[var].dropna(),
    bins=13,
    edgecolor='black'
)
ax.set_title(var)
ax.set_xlabel('')
ax.set_ylabel('Frequência')
ax.grid(axis='y', alpha=0.3)
axes.flat[5].set_visible(False)
plt.tight_layout() plt.show()
```

2.3 Boxplots individuais

```
for variavel in variaveis_quant:
plt.figure(figsize=(8, 3))
sns.boxplot(x=dados_quant[variavel])
plt.title(f'Boxplot de {variavel}')
plt.xlabel(variavel)
plt.tight_layout()
plt.show()
```

2.4 Padronização das variáveis quantitativas

```
scaler = StandardScaler()
dados_padronizados = pd.DataFrame( scaler.fit_transform(dados_quant), columns=variaveis_quant )
```

plt.figure(figsize=(10, 5))

sns.boxplot(data=dados_padronizados)

plt.title('Boxplots das variáveis quantitativas padronizadas') plt.xlabel('Variáveis') plt.ylabel('Valor padronizado (z-score)')

plt.tight_layout() plt.show()

2.5 Correlação de Pearson

corr_pearson = dados_quant.corr(method='pearson')

display(corr_pearson)

plt.figure(figsize=(8, 6))

sns.heatmap(corr_pearson, annot=True, fmt='.2f', cmap='coolwarm', vmin=-1, vmax=1, center=0)

plt.title('Matriz de correlação de Pearson') plt.tight_layout() plt.show()

2.6 Correlação de Spearman

corr_spearman = dados_quant.corr(method='spearman')

display(corr_spearman)

plt.figure(figsize=(8, 6))

sns.heatmap(corr_spearman, annot=True, fmt='.2f', cmap='coolwarm', vmin=-1, vmax=1, center=0)

plt.title('Matriz de correlação de Spearman') plt.tight_layout() plt.show()

2.7 Comparação entre Pearson e Spearman

comparacao_corr = pd.DataFrame({ 'Pearson': corr_pearson.stack(), 'Spearman': corr_spearman.stack() })

display(comparacao_corr)

2.8 Relações entre as variáveis quantitativas

sns.pairplot(dados_quant, diag_kind='hist')

plt.show()

==========

3. ANÁLISE DAS VARIÁVEIS QUALITATIVAS ORDINAIS

==========

variaveis_ordinais = ['conta_corrente', 'historico_credito', 'conta_poupanca', 'tempo_emprego', 'taxa_parcela', 'tempo_moradia', 'patrimonio']

3.1 Frequências, mediana e quartis

```
for var in variaveis_ordinais:
print(f'\nVariável: {var}')

freq = df[var].value_counts().sort_index()

perc = (
    df[var].value_counts(normalize=True)
    .sort_index() * 100
)

tabela = pd.DataFrame({
    'Frequência': freq,
    'Percentual (%)': perc.round(2)
})

display(tabela)

print(f'Mediana: {df[var].median()}')
print(f'Q1: {df[var].quantile(0.25)}')
print(f'Q3: {df[var].quantile(0.75)}')
```

3.2 Gráficos de barras das variáveis ordinais

```
for var in variaveis_ordinais:
frequencias = df[var].value_counts().sort_index()

plt.figure(figsize=(7, 4))

plt.bar(
```

```
    frequencias.index.astype(str),
    frequencias.values
)

plt.title(f'Distribuição de {var}')
plt.xlabel('Categoria')
plt.ylabel('Frequência')

plt.tight_layout()
plt.show()
```

3.3 Correlação de Spearman entre variáveis ordinais

```
correlacao_spearman = ( df[variaveis_ordinais].corr(method='spearman') )
display(correlacao_spearman.round(3))
plt.figure(figsize=(9, 7))
sns.heatmap( correlacao_spearman, annot=True, fmt='.2f', cmap='coolwarm', center=0 )
plt.title('Correlação de Spearman entre variáveis ordinais') plt.tight_layout() plt.show()
```

==========

4. ANÁLISE DAS VARIÁVEIS QUALITATIVAS

==========

```
variaveis_qualitativas = [ 'conta_corrente', 'historico_credito', 'finalidade', 'conta_poupanca', 'tempo_emprego', 'estado_civil_sexo', 'fiador', 'patrimonio', 'outros_creditos', 'tipo_moradia', 'profissao', 'telefone', 'trabalhador_estrangeiro' ]
```

4.1 Frequências e tabelas de contingência

```
for var in variaveis_qualitativas:
dados = df[[var, 'classe_credito']].dropna()
print(f'\n{"="*50}')
print(f'Variável: {var}')
print(f'{"="*50}')
freq = dados[var].value_counts().sort_index()
```

```
display(freq.to_frame('Frequência'))
tabela = pd.crosstab(
    dados[var],
    dados['classe_credito']
).reindex(columns=[0, 1], fill_value=0)
tabela.columns = [
    'Crédito bom (0)',
    'Crédito ruim (1)'
]
print("\nTabela de contingência:")
display(tabela)
percentual = pd.crosstab(
    dados[var],
    dados['classe_credito'],
    normalize='index'
).reindex(columns=[0, 1], fill_value=0) * 100

percentual.columns = [
    'Crédito bom (0)',
    'Crédito ruim (1)'
]

print("\nDistribuição percentual por categoria:")
display(percentual.round(2))
```

==========

5. GRÁFICOS DAS PRINCIPAIS VARIÁVEIS QUALITATIVAS

==========

```
variaveis_principais = { 'conta_corrente': 'Conta corrente', 'historico_credito': 'Histórico de crédito', 'conta_poupanca': 'Conta poupança', 'finalidade': 'Finalidade do crédito', 'patrimonio': 'Patrimônio' }
```

```
cor_bom = '#4472C4' cor_ruim = '#ED7D31'
for variavel, titulo in variaveis_principais.items():
tabela = pd.crosstab(
    df[variavel],
    df['classe_credito']
).reindex(columns=[0, 1], fill_value=0)
percentuais = tabela.div(
    tabela.sum(axis=1), axis=0
) * 100

categorias = tabela.index.astype(str)
x = np.arange(len(categorias))
largura = 0.35

fig, ax = plt.subplots(figsize=(11, 6))

ax.bar(
    x - largura/2,
    percentuais[0],
    largura,
    label='Crédito bom (0)',
    color=cor_bom
)
ax.bar(
    x + largura/2,
    percentuais[1],
    largura,
    label='Crédito ruim (1)',
    color=cor_ruim
```

```
)
for i in range(len(categorias)):
    ax.text(
        x[i] - largura/2,
        percentuais.iloc[i, 0] + 1,
        f'{tabela.iloc[i, 0]}\n{percentuais.iloc[i, 0]:.1f}%',
        ha='center',
        fontsize=9
    )
    ax.text(
        x[i] + largura/2,
        percentuais.iloc[i, 1] + 1,
        f'{tabela.iloc[i, 1]}\n{percentuais.iloc[i, 1]:.1f}%',
        ha='center',
        fontsize=9
    )
ax.set_title(
    f'Classificação de crédito por {titulo.lower()}'
)
ax.set_xlabel(titulo)
ax.set_ylabel('Percentual de clientes (%)')
ax.set_xticks(x)
ax.set_xticklabels(categorias, rotation=0)
ax.set_ylim(0, 115)
ax.legend(title='Classe de crédito')
ax.grid(axis='y', linestyle='--', alpha=0.4)
plt.tight_layout()
plt.show()
```

```
============================================================
```

6. TESTE DO QUI-QUADRADO E V DE CRAMÉR

```
============================================================
```

```
resultados = []
for var in variaveis_qualitativas:
dados = df[[var, 'classe_credito']].dropna()
tabela = pd.crosstab(
    dados[var],
    dados['classe_credito']
).reindex(columns=[0, 1], fill_value=0)
chi2, p_valor, gl, esperadas = chi2_contingency(tabela)
n = tabela.to_numpy().sum()
r, c = tabela.shape

v_cramer = np.sqrt(
    chi2 / (n * min(r - 1, c - 1))
)
resultados.append({
    'Variável': var,
    'Qui-quadrado': chi2,
    'Graus de liberdade': gl,
    'p-valor': p_valor,
    'V de Cramér': v_cramer,
    'Menor frequência esperada': esperadas.min()
})
resultado_associacao = pd.DataFrame(resultados)
print("\nResultados dos testes de associação:")
display(resultado_associacao.round(4))
```

==========

7. RESÍDUOS DE PEARSON

==========

variaveis_residuos = ['conta_corrente', 'historico_credito', 'conta_poupanca', 'finalidade', 'patrimonio']

Cálculo dos resíduos para as cinco variáveis selecionadas

```
residuos_por_variavel = {}
for var in variaveis_residuos:
dados = df[[var, 'classe_credito']].dropna()
tabela = pd.crosstab(
    dados[var],
    dados['classe_credito']
).reindex(columns=[0, 1], fill_value=0)

chi2, p, gl, esperadas = chi2_contingency(tabela)
residuos = (
    tabela.to_numpy() - esperadas
) / np.sqrt(esperadas)

residuos = pd.DataFrame(
    residuos,
    index=tabela.index,
    columns=['Crédito bom (0)', 'Crédito ruim (1)']
)
residuos_por_variavel[var] = residuos
print(f"\n{'='*55}")
print(f'Resíduos de Pearson: {var}")
print(f'{'='*55}")
display(residuos.round(2))
```

7.1 Seleção das 14 categorias utilizadas nos gráficos

```
categorias_residuos = { 'conta_corrente': ['1', '2', '4'], 'historico_credito': ['0', '1', '4'], 'conta_poupanca': ['1', '4', '5'], 'finalidade': ['0', '1', '3'], 'patrimonio': ['1', '4'] }

registros = []

for var, categorias in categorias_residuos.items():

residuos = residuos_por_variavel[var]

for categoria in categorias:

    for indice in residuos.index:

        if str(indice) == categoria:

            registros.append({

                'Categoria': f'{var} - {categoria}',

                'Classe 0': residuos.loc[

                    indice, 'Crédito bom (0)'

                ],

                'Classe 1': residuos.loc[

                    indice, 'Crédito ruim (1)'

                ]

            })

df_residuos = pd.DataFrame(registros)
```

7.2 Gráficos dos resíduos – classe 0 e classe 1

```
for coluna, titulo in [ ('Classe 0', 'Resíduos de Pearson – Crédito bom (classe 0)'), ('Classe 1', 'Resíduos de Pearson – Crédito ruim (classe 1)') ]:

df_plot = df_residuos.sort_values(coluna)

plt.figure(figsize=(10, 7))

plt.barh(

    df_plot['Categoria'],

    df_plot[coluna]

)


plt.axvline(0, color='black', linewidth=0.8)
```

```
plt.axvline(2, color='red', linestyle='--', label='Limite +2')
plt.axvline(-2, color='red', linestyle='--', label='Limite -2')


plt.xlabel('Resíduo de Pearson')
plt.ylabel('Categorias')
plt.title(titulo)
plt.legend()
plt.grid(axis='x', alpha=0.3)
plt.tight_layout()
plt.show()
```

==========

8. COMPARAÇÃO DAS VARIÁVEIS QUANTITATIVAS

POR CLASSE DE CRÉDITO

==========

```
comparacao = df.groupby('classe_credito')[variaveis_quant].agg( ['mean', 'median', 'std', 'min', 'max'] )
display(comparacao.round(2))
display(df['classe_credito'].value_counts())
```

==========

9. VERIFICAÇÃO FINAL DOS DADOS

==========

```
print("\nDistribuição final da classe de crédito:")
display( df['classe_credito'].value_counts().sort_index() )
print("\nValores ausentes por variável:")
display( df.isnull().sum().to_frame('Valores ausentes') )
print("\nAnálise exploratória de dados concluída.")
```

==========

FIM DO PROGRAMA

==========

Referências bibliográficas

Agresti, A. (2007). *An introduction to categorical data analysis* (2nd ed.). John Wiley & Sons.

Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical statistics for data scientists: 50+ essential concepts using R and Python* (2nd ed.). O'Reilly Media.

Hofmann, H. (1994). *Statlog (German Credit Data).* UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/144/statlog+german+credit+data

McKinney, W. (2022). *Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter* (3rd ed.). O'Reilly Media.

Pearson, K. (1900). X. On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science, 50*(302), 157–175. https://doi.org/10.1080/14786440009463897

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.